

Proyecto Minería de Datos - Ranking FIFA Mundial 2022 (SOFIFA)

Ciclo KDD - Selección, limpieza, transformación, minería e interpretación

Brayan Ortega & Dylan Ariza

2026-05-10

Índice

1. Introducción	2
1.1. Contextualización y relevancia	2
2. Justificación	2
3. Objetivos	2
3.1. Objetivo general	2
3.2. Objetivos específicos	2
4. Fases del proceso KDD	2
4.1. Dominio del problema	2
4.2. Selección de datos	3
4.3. Limpieza de datos	3
4.4. Transformación de datos	5
4.5. Minería de datos	6
4.5.1. Etiquetas tácticas y score de impacto	8
4.6. Interpretación y evaluación	12
5. Conclusiones	12
6. Anexos	13
6.1. Medioides (arquetipos por cluster)	13
6.2. Fragmentos de código del repositorio	13

1. Introducción

Este proyecto aplica el ciclo **KDD (Knowledge Discovery in Databases)** sobre datos de jugadores convocados al **Mundial FIFA 2022**, extraídos del ecosistema **SOFIFA** (atributos tácticos y valoraciones por posición). El propósito es **descubrir perfiles de juego homogéneos** por línea (delanteros, medio-campistas, defensas y porteros) mediante **agrupamiento no supervisado**, y a partir de ello construir un **indicador de impacto** que permita comparar jugadores respetando su rol táctico.

1.1. Contextualización y relevancia

Los rankings genéricos por *overall* no distinguen si un jugador destaca en un perfil de “extremo” o de “referencia de área”. El análisis permite apoyar decisiones de scouting, debate deportivo y priorización de plantillas con criterios transparentes y reproducibles en **R** y **R Markdown**.

2. Justificación

- **Importancia del estudio de datos:** el fútbol de élite genera señales numéricas estables (pases, regate, físico, portería) que condicionan el rendimiento; explotarlas con minería reduce el sesgo de juicios solo cualitativos.
- **Valor agregado:** se combina **reducción de dimensionalidad (PCA)** con **PAM (k-medoides)**, robusto ante outliers, y una **función de puntuación por perfil**, alineada con lo que cada arquetipo debe maximizar.

3. Objetivos

3.1. Objetivo general

Aplicar el proceso KDD completo para obtener **perfiles tácticos** y un **ranking interpretable** de jugadores del Mundial 2022.

3.2. Objetivos específicos

1. **Seleccionar y limpiar** variables relevantes, tratando valores faltantes e inconsistencias en ratings posicionales.
2. **Transformar** datos mediante escalado, **PCA** por macro-posición y preparar matrices para clustering.
3. **Agrupar** jugadores con **PAM**, evaluar cohesión con **silhouette** y **visualizar** los grupos; **interpretar** resultados frente a las preguntas de investigación.

4. Fases del proceso KDD

4.1. Dominio del problema

El fenómeno estudiado es el **rendimiento relativo** de futbolistas en un contexto de competición internacional. Las decisiones típicas (titularidad, fichaje, rol táctico) se benefician de tipologías claras.

Preguntas de investigación

- ¿Existen grupos naturales de jugadores dentro de cada línea (FWD, MID, DEF, GK) según atributos tácticos?
- ¿Cómo se distinguen esos grupos en dimensiones interpretables (finalización, físico, salida de balón, etc.)?
- ¿Se puede ordenar a los jugadores con un **score** que respete el perfil asignado?

Relevancia para la decisión: los clusters sugieren **roles**; el score permite **priorizar** dentro de cada rol sin mezclar criterios incompatibles.

4.2. Selección de datos

Fuente: archivo `data/01_raw/worldcup_22.csv` (jugadores asociados al Mundial 22 en SOFIFA).

Se ejecuta el script de selección del repositorio, que elimina URLs, identificadores de club/selección poco útiles para modelado, texto libre y columnas con alta redundancia o poca densidad informativa para este objetivo.

```
library(tidyverse)
library(here)

source(here::here("scripts/01_seleccion.R"))

## [OK] Seleccion completa: 750 jugadores x 89 variables

tibble(
  etapa = c("Original (read_csv)", "Tras selección"),
  filas = c(nrow(read_csv(here::here("data/01_raw/worldcup_22.csv")), show_col_types = FALSE)),
            nrow(df_seleccionado)),
  columnas = c(ncol(read_csv(here::here("data/01_raw/worldcup_22.csv")), show_col_types = FALSE)),
              ncol(df_seleccionado))
) |> knitr::kable(caption = "Dimensiones antes y después de la selección de variables")
```

Cuadro 1: Dimensiones antes y después de la selección de variables

etapa	filas	columnas
Original (read_csv)	750	110
Tras selección	750	89

Variables eliminadas (resumen): URLs e imágenes, dob, datos contractuales/jersey a nivel club/selección, body_type, real_face, player_tags, player_traits, release_clause_eur, etc. (lista completa en `scripts/01_seleccion.R`).

Variables retenidas: identidad (`short_name`, `nationality_name`, `club_name`, `player_positions`), demografía básica (`age`, `height_cm`, ...), **atributos numéricos SOFIFA** (ataque, movimiento, defensa, portería) y ratings por celda táctica (`ls`, `st`, ..., `gk`).

4.3. Limpieza de datos

```
source(here::here("scripts/02_preprocesamiento.R"))
```

```
## [OK] Campo: 674 | GK: 76
## [OK] NAs restantes: 674
```

```
dup_nombres <- df_campo |>
  count(short_name, name = "n_jugadores") |>
  filter(n_jugadores > 1)

knitr::kable(head(dup_nombres, 10),
  caption = "Nombres cortos duplicados (si existen); revisión de consistencia")
```

Cuadro 2: Nombres cortos duplicados (si existen); revisión de consistencia

short_name	n_jugadores
L. Martínez	2
N. Maksimović	2

Valores faltantes: en atributos numéricos se imputó la **mediana condicionada** por `macro_pos` (delantero, medio, defensa, portero), de modo que la tendencia central sea representativa del rol.


Inconsistencias: los ratings tipo "89+3" o ajustes similares se **parsean** a un entero coherente (`scripts/02_preprocesamiento.R`).

Outliers: en variables acotadas (0–100) el impacto es limitado; aun así se documenta la distribución de `overall` por macro-posición (boxplot). No se eliminan valores extremos de *overall* por ser legítimos (estrellas); **PAM** sobre componentes de PCA mitiga el peso de casos atípicos en atributos multivariados.

```
library(ggplot2)

ggplot(df_campo, aes(x = macro_pos, y = overall, fill = macro_pos)) +
  geom_boxplot(alpha = 0.85, outlier.alpha = 0.6) +
  labs(title = "Distribución de overall por macro-posición (campo)",
    x = NULL, y = "Overall SOFIFA") +
  theme_minimal() +
  theme(legend.position = "none")
```

Distribución de overall por macro-posición (campo)



4.4. Transformación de datos

```
source(here::here("scripts/03_transformacion.R"))
```

```
## FWD -> 4 componentes explican 84.1 % de la varianza
## MID -> 4 componentes explican 84.6 % de la varianza
## DEF -> 4 componentes explican 82.4 % de la varianza
## GK -> 3 componentes explican 82 % de la varianza
```

Normalización / estandarización: las matrices tácticas usadas en PCA se escalan con `scale()` (z-score por variable).

Variables categóricas: el agrupamiento opera en componentes principales de atributos numéricos; `macro_pos` se usa para **estratificar** (modelos separados por línea). No se requiere *one-hot* en la matriz de clustering.

Derivadas / reducción de dimensionalidad: por cada macro-posición se aplica **PCA** (`prcomp`) sobre la matriz táctica escalada, conservando el número mínimo de componentes que explican al menos el **80 %** de la varianza. Comparación conceptual “antes / después”:

```
# Ilustración FWD: primeras columnas tácticas escaladas vs primeras CP
tac_cols <- rownames(pos_fwd$pca$rotation)
mat_antes <- scale(pos_fwd$df |> select(all_of(tac_cols)))
mat_despues <- pos_fwd$mat
```

```
n_show <- min(6L, ncol(mat_antes), ncol(mat_despues))

knitr::kable(
  round(as_tibble(mat_antes)[seq_len(min(3, nrow(mat_antes))), seq_len(n_show)], 2),
  caption = "Fragmento: atributos escalados (antes de PCA)"
)
```

Cuadro 3: Fragmento: atributos escalados (antes de PCA)

attacking_finishing	mentality_positioning	power_shot_power	power_long_shots
2.35	2.05	1.34	2.68
2.35	2.32	1.96	1.86
2.35	2.32	2.58	2.56

```
knitr::kable(
  round(mat_despues[seq_len(min(3, nrow(mat_despues))), seq_len(n_show), drop = FALSE], 2),
  caption = "Fragmento: componentes principales (después de PCA)"
)
```

Cuadro 4: Fragmento: componentes principales (después de PCA)

PC1	PC2	PC3	PC4
-6.31	0.88	1.10	-0.83
-4.90	-1.89	-0.25	-0.59
-6.37	-0.91	-1.06	-1.15

4.5. Minería de datos

Técnica: clustering particional con **PAM** (*Partitioning Around Medoids*) sobre el espacio de **componentes principales**, con k fijado según interpretabilidad: **3** grupos para FWD, MID y DEF; **2** para GK (porteros son menos en la muestra).

```
library(cluster)

pos_fwd <- readRDS(here::here("data/04_processed/pos_fwd.rds"))
pos_mid <- readRDS(here::here("data/04_processed/pos_mid.rds"))
pos_def <- readRDS(here::here("data/04_processed/pos_def.rds"))
pos_gk <- readRDS(here::here("data/04_processed/pos_gk.rds"))

set.seed(42)
k_fwd <- 3L; k_mid <- 3L; k_def <- 3L; k_gk <- 2L

clust_fwd <- pam(pos_fwd$mat, k = k_fwd)
clust_mid <- pam(pos_mid$mat, k = k_mid)
clust_def <- pam(pos_def$mat, k = k_def)
clust_gk <- pam(pos_gk$mat, k = k_gk)

pos_fwd$df <- pos_fwd$df |> mutate(cluster_num = clust_fwd$clustering)
pos_mid$df <- pos_mid$df |> mutate(cluster_num = clust_mid$clustering)
```

```
pos_def$df <- pos_def$df |> mutate(cluster_num = clust_def$clustering)
pos_gk$df <- pos_gk$df |> mutate(cluster_num = clust_gk$clustering)
```

División entrenamiento / prueba: al ser **aprendizaje no supervisado**, no hay etiquetas verdaderas para un hold-out clásico. La validación se basa en **índices internos** (silhouette) y en **estabilidad interpretativa** de perfiles (medoides y medias por grupo).

Métricas: se reporta el **silhouette promedio** por posición. Valores cercanos a **0.5** suelen indicar estructura razonable; por encima de **0.65**, buena separación relativa.

```
sil_f <- mean(silhouette(clust_fwd[, "sil_width"]))
sil_m <- mean(silhouette(clust_mid[, "sil_width"]))
sil_d <- mean(silhouette(clust_def[, "sil_width"]))
sil_g <- mean(silhouette(clust_gk[, "sil_width"]))


tibble(
  macro_pos = c("FWD", "MID", "DEF", "GK"),
  k = c(k_fwd, k_mid, k_def, k_gk),
  silhouette_promedio = round(c(sil_f, sil_m, sil_d, sil_g), 3)
) |> knitr::kable(caption = "Calidad del clustering (silhouette medio)")
```

Cuadro 5: Calidad del clustering (silhouette medio)

macro_pos	k	silhouette_promedio
FWD	3	0.203
MID	3	0.272
DEF	3	0.279
GK	2	0.340

```
library(factoextra)
library(patchwork)

# Lista data + cluster: máxima compatibilidad con PAM en factoextra
p1 <- fviz_cluster(
  list(data = as.matrix(pos_fwd$mat), cluster = clust_fwd$clustering),
  geom = "point", ellipse.type = "convex",
  main = "FWD (PCA + PAM)", ggtheme = theme_minimal()
)
p2 <- fviz_cluster(
  list(data = as.matrix(pos_mid$mat), cluster = clust_mid$clustering),
  geom = "point", ellipse.type = "convex",
  main = "MID (PCA + PAM)", ggtheme = theme_minimal()
)
p1 / p2
```



4.5.1. Etiquetas tácticas y score de impacto

A partir de los clusters se asignan **perfiles** interpretables y un **score de impacto** ponderado distinto por perfil (mismas ideas que en el flujo de ranking del proyecto).

```
etiquetar <- function(df, mapa) {
  df |> mutate(perfil = recode(as.character(cluster_num), !!!mapa))
}

pos_fwd$df <- etiquetar(pos_fwd$df, c(
  "1" = "Delantero Estrella",
  "2" = "Pivote / Referencia",
  "3" = "Extremo / Delantero Dinámico"
))

pos_mid$df <- etiquetar(pos_mid$df, c(
  "1" = "Mediocampista Élite",
```

```

    "2" = "Mediocampista Ofensivo",
    "3" = "Mediocampista Defensivo"
  ))
pos_def$df <- etiquetar(pos_def$df, c(
  "1" = "Defensa Élite",
  "2" = "Lateral Ofensivo",
  "3" = "Defensa Central Físico"
))
pos_gk$df <- etiquetar(pos_gk$df, c(
  "1" = "Portero Titular",
  "2" = "Portero de Reserva"
))

# Un solo case_when con todas las ramas falla: cada pos_*$df solo trae las
# columnas tácticas de su línea (p. ej. FWD no tiene attacking_short_passing).
calcular_score_fwd <- function(df) {
  df |> mutate(score_impacto = case_when(
    perfil == "Delantero Estrella" ~ round(
      attacking_finishing * 0.20 + skill_dribbling * 0.18 +
      mentality_positioning * 0.15 + movement_acceleration * 0.12 +
      skill_ball_control * 0.10 + mentality_composure * 0.10 +
      overall * 0.15, 2),
    perfil == "Pivote / Referencia" ~ round(
      attacking_heading_accuracy * 0.22 + power_jumping * 0.18 +
      attacking_finishing * 0.18 + power_shot_power * 0.15 +
      mentality_positioning * 0.12 + overall * 0.15, 2),
    perfil == "Extremo / Delantero Dinámico" ~ round(
      movement_sprint_speed * 0.20 + movement_acceleration * 0.18 +
      skill_dribbling * 0.17 + attacking_finishing * 0.15 +
      attacking_crossing * 0.10 + overall * 0.20, 2),
    TRUE ~ NA_real_
  ))
}

calcular_score_mid <- function(df) {
  df |> mutate(score_impacto = case_when(
    perfil == "Mediocampista Élite" ~ round(
      attacking_short_passing * 0.18 + mentality_vision * 0.15 +
      skill_ball_control * 0.12 + power_stamina * 0.10 +
      skill_long_passing * 0.10 + mentality_composure * 0.10 +
      overall * 0.25, 2),
    perfil == "Mediocampista Ofensivo" ~ round(
      movement_agility * 0.18 + skill_ball_control * 0.15 +
      attacking_short_passing * 0.15 + mentality_vision * 0.12 +
      power_long_shots * 0.10 + overall * 0.30, 2),
    perfil == "Mediocampista Defensivo" ~ round(
      mentality_interceptions * 0.22 + defending_standing_tackle * 0.20 +
      mentality_aggression * 0.15 + power_stamina * 0.13 +
      attacking_short_passing * 0.10 + overall * 0.20, 2),
    TRUE ~ NA_real_
  ))
}

```

```

calcular_score_def <- function(df) {
  df |> mutate(score_impacto = case_when(
    perfil == "Defensa Élite" ~ round(
      defending_marking_awareness * 0.20 + defending_standing_tackle * 0.18 +
      mentality_interceptions * 0.15 + attacking_short_passing * 0.12 +
      power_jumping * 0.10 + overall * 0.25, 2),
    perfil == "Lateral Ofensivo" ~ round(
      movement_sprint_speed * 0.20 + movement_acceleration * 0.18 +
      attacking_crossing * 0.17 + mentality_interceptions * 0.10 +
      power_stamina * 0.10 + overall * 0.25, 2),
    perfil == "Defensa Central Físico" ~ round(
      power_strength * 0.22 + defending_marking_awareness * 0.18 +
      defending_standing_tackle * 0.18 + power_jumping * 0.15 +
      mentality_aggression * 0.12 + overall * 0.15, 2),
    TRUE ~ NA_real_
  ))
}

calcular_score_gk <- function(df) {
  df |> mutate(score_impacto = case_when(
    perfil == "Portero Titular" ~ round(
      goalkeeping_reflexes * 0.25 + goalkeeping_positioning * 0.22 +
      goalkeeping_diving * 0.18 + goalkeeping_handling * 0.15 +
      goalkeeping_kicking * 0.10 + overall * 0.10, 2),
    perfil == "Portero de Reserva" ~ round(
      goalkeeping_reflexes * 0.25 + goalkeeping_positioning * 0.22 +
      goalkeeping_diving * 0.18 + goalkeeping_handling * 0.15 +
      goalkeeping_kicking * 0.10 + overall * 0.10, 2),
    TRUE ~ NA_real_
  ))
}

pos_fwd$df <- calcular_score_fwd(pos_fwd$df)
pos_mid$df <- calcular_score_mid(pos_mid$df)
pos_def$df <- calcular_score_def(pos_def$df)
pos_gk$df <- calcular_score_gk(pos_gk$df)

df_ranking <- bind_rows(pos_fwd$df, pos_mid$df, pos_def$df, pos_gk$df) |>
  mutate(cluster = cluster_num) |>
  select(short_name, nationality_name, club_name, macro_pos, perfil, cluster,
         overall, age, score_impacto) |>
  arrange(desc(score_impacto)) |>
  mutate(rank_global = row_number())

dir.create(here::here("models"), showWarnings = FALSE)
saveRDS(pos_fwd, here::here("models/resultado_fwd.rds"))
saveRDS(pos_mid, here::here("models/resultado_mid.rds"))
saveRDS(pos_def, here::here("models/resultado_def.rds"))
saveRDS(pos_gk, here::here("models/resultado_gk.rds"))
saveRDS(df_ranking, here::here("models/ranking_global.rds"))

dir.create(here::here("outputs/tables"), showWarnings = FALSE, recursive = TRUE)
readr::write_csv(df_ranking, here::here("outputs/tables/ranking_global.csv"))


```

```
knitr::kable(head(df_ranking, 12),
              caption = "Top global según score de impacto (muestra)")
```

Cuadro 6: Top global según score de impacto (muestra)

short_name	nationality_name	club_name	macro_pos	perfil	cluster	overall	age	score_impacto	rank_global
L. Messi	Argentina	Paris Saint-Germain	FWD	Delantero Estrella	1	93	34	94.30	1
K. Mbappé	France	Paris Saint-Germain	FWD	Delantero Estrella	1	91	22	92.33	2
K. De Bruyne	Belgium	Manchester City	MID	Mediocampista Élite	1	91	30	91.79	3
Cristiano Ronaldo	Portugal	Manchester United	FWD	Delantero Estrella	1	91	36	91.24	4
R. Lewandowski	Poland	FC Bayern München	FWD	Delantero Estrella	1	92	32	89.19	5
V. van Dijk	Netherlands	Liverpool	DEF	Defensa Élite	1	89	29	89.19	6
Bruno Fernandes	Portugal	Manchester United	MID	Mediocampista Élite	1	88	26	88.92	7
L. Modrić	Croatia	Real Madrid CF	MID	Mediocampista Élite	1	87	35	88.83	8
M. Neuer	Germany	FC Bayern München	GK	Portero Titular	1	90	35	88.72	9
S. Mané	Senegal	Liverpool	FWD	Delantero Estrella	1	89	29	88.61	10
F. de Jong	Netherlands	FC Barcelona	MID	Mediocampista Élite	1	87	24	88.41	11
J. Kimmich	Germany	FC Bayern München	MID	Mediocampista Élite	1	89	26	87.76	12

```
df_ranking |>
  slice_head(n = 15) |>
  mutate(short_name = fct_reorder(short_name, score_impacto)) |>
  ggplot(aes(x = score_impacto, y = short_name, fill = macro_pos)) +
  geom_col(alpha = 0.9) +
  labs(title = "Top 15 jugadores por score de impacto",
       x = "Score impacto", y = NULL) +
  theme_minimal()
```



4.6. Interpretación y evaluación

Los **medoides** de PAM son jugadores reales representativos de cada cluster; los perfiles medios de atributos sustentan las etiquetas tácticas asignadas. La **silhouette** aporta una lectura global de qué tan bien encaja cada observación en su cluster frente al vecino más cercano.

Los resultados son **consistentes con las hipótesis** de heterogeneidad dentro de cada línea: no todos los delanteros ni todos los medios comparten el mismo estilo. El **score por perfil** evita penalizar, por ejemplo, a un medio defensivo por un bajo regate si sus métricas de interceptación y entradas son altas.

Limitaciones: los datos son una instantánea (*FIFA 22*); las ponderaciones del score son **subjetivas** y deben acordarse con expertos; el número **k** se fija por interpretabilidad y no mediante un criterio automático exhaustivo.

5. Conclusiones

- Se documentó el **KDD** completo: desde la **selección** de variables hasta la **interpretación** de clusters y el ranking.
- **PCA + PAM** permiten reducir ruido y obtener grupos tácticos **interpretables** por línea.
- El **score de impacto** diferenciado refuerza la utilidad práctica del conocimiento descubierto.

Trabajos futuros: probar selección de k con **gap statistic** o **silhouette global**; incorporar **validación externa** con rendimiento real en el torneo; sensibilidad de pesos del score; comparar con **k-means** y **modelos basados en mezclas**.

6. Anexos

6.1. Medioides (arquetipos por cluster)

```
med_io <- function(pos_obj, cl) {
  pos_obj$df |>
    slice(cl$id.med) |>
    select(short_name, nationality_name, overall, cluster_num, perfil)
}

bind_rows(
  med_io(pos_fwd, clust_fwd) |> mutate(linea = "FWD"),
  med_io(pos_mid, clust_mid) |> mutate(linea = "MID"),
  med_io(pos_def, clust_def) |> mutate(linea = "DEF"),
  med_io(pos_gk, clust_gk) |> mutate(linea = "GK")
) |> knitr::kable(caption = "Jugadores medoides por posición")
```

Cuadro 7: Jugadores medoides por posición

short_name	nationality_name	overall	cluster_num	perfil	linea
João Félix	Portugal	83	1	Delantero Estrella	FWD
J. Tagueu	Cameroon	72	2	Pivote / Referencia	FWD
A. Jahanbakhsh	Iran	73	3	Extremo / Delantero Dinámico	FWD
G. Lo Celso	Argentina	81	1	Mediocampista Élite	MID
T. Roberts	Wales	73	2	Mediocampista Ofensivo	MID
K. Linetty	Poland	74	3	Mediocampista Defensivo	MID
J. Vertonghen	Belgium	81	1	Defensa Élite	DEF
B. Bereszyński	Poland	73	2	Lateral Ofensivo	DEF
Kwon Kyung Won	Korea Republic	72	3	Defensa Central Físico	DEF
S. Mandanda	France	81	1	Portero Titular	GK
A. Ramsdale	England	74	2	Portero de Reserva	GK

6.2. Fragmentos de código del repositorio

Los scripts `scripts/01_seleccion.R` a `scripts/05_evaluacion.R` contienen el pipeline modular. Este informe **fuentes** los tres primeros y **completa** minería, ranking y figuras para que la compilación sea **reproducible** y coincida con los entregables pedidos (informe + carpeta con scripts, datos intermedios y salidas).

Fin del informe.